

分类模型

第一部分 线性分类模型

第二部分 非线性分类模型

SVM

张朝晖

2018-2019学年 20180918-0926

1.分类模块

产生式分类模型

A.贝叶斯分类模型

判别式分类模型

线性分类模型

- B. Fisher判别分类
- C. 感知器分类模型
- D. 大间隔分类模型(线性SVM)

非线性分类模型

- E. 核SVM(非线性SVM)
- F. 核Fisher判别分类
- G. 神经网络

其它分类模型

- H.KNN分类模型
- I.决策树分类模型
- J.Logistic回归
- K.Softmax回归

2.聚类模块

- L.K-均值聚类
- M.高斯混合聚类
- N.DBSCAN聚类
- O.层次聚类

3.回归模块

- P.KNN回归
- Q.回归树
- R.最小二乘线性回归
- S.岭回归
- T.LASSO回归

4.集成学习

- U.Bagging
- V.随机森林
- W.Boosting

5.特征工程

- X.主成分分析(PCA)
- ...

6.评价模块

混淆矩阵(及其相关指标)、ROC曲线、交叉验证

主要内容

A. 引言

B. Fisher线性判别分析

C. 感知器

D. 线性支持向量机(线性SVM)

Support Vector Machine: SVM

学习要求:

- 理解SVM分类模型构建的基本思想
- 掌握SVM目标函数的构造形式、意义
- 掌握SVM分类模型的学习步骤、使用流程
- 掌握SVM进行超参数寻优的典型方法
- 能够熟练应用SVM进行分类(两类别、多类别)

关键词:

- 分类间隔、分类边界、判别函数
- 训练样本集的错分程度
- 分类超平面、超平面法向量、超参数
- 支持向量、非支持向量
- 判别函数、分类边界

➤ SVM(Support Vector Machine)是支持向量机的简称。
“机”,对应机器学习中的“机器”,是“算法”的意思。

所谓支持向量机就是一种与“支持向量”有关的机器学习算法。

➤ SVM 的求解最后转化成凸二次规划问题的求解,因此SVM 的解是全局唯一的最优解。

➤ SVM在解决小样本(样本数<特征维数)、非线性、高维模式分类问题中表现出许多特有的优势,并能够推广应用到函数拟合(回归)等其它机器学习问题中。

➤ SVM 用于分类,就是 SVC (Support Vector Classification); 用于回归就是SVR (Support Vector Regression)。

第1部分

两类别分类情况下的线性SVC

主要内容

- 1 两类别分类问题：线性可分情况
- 2 两类别分类问题：近似线性可分情况
- 3 多类别的线性SVM
- 4 应用举例

SVM始于两类问题的解决需求

两类别分类问题的描述：

给定训练集 $T = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$

$$\text{其中} \begin{cases} \mathbf{x}_i \in R^d \\ y_i \in \mathcal{Y} = \{1, -1\} \end{cases} \quad i = 1, 2, \dots, N$$

要求：寻找 R^d 空间上的一个实值函数 $g(\mathbf{x})$, 从而可用
决策函数 $f(\mathbf{x}) = \text{sgn}(g(\mathbf{x})) : R^d \rightarrow \mathcal{Y}$;
推断任意输入 \mathbf{x} 对应的输出值 y .

线性可分问题-定义:

给定**训练集** $T = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$

其中 $\mathbf{x}_i \in R^d, i = 1, 2, \dots, N$


$y_i \in \mathcal{Y} = \{1, -1\}$

若存在 $\omega \in R^d, b \in R$,以及正数 ε , 使得

$$\begin{cases} \text{对于所有 } y_i = +1 \text{ 的样本 } \mathbf{x}_i, \text{ 有 } g(\mathbf{x}_i) = \omega \bullet \mathbf{x}_i + b \geq \varepsilon \\ \text{对于所有 } y_i = -1 \text{ 的样本 } \mathbf{x}_i, \text{ 有 } g(\mathbf{x}_i) = \omega \bullet \mathbf{x}_i + b \leq -\varepsilon. \end{cases}$$


则称**训练集** T 线性可分。

1. 例：二维、两类、线性可分情况



问题：可能存在许多分类边界（决策边界），若将两类完全分开，应当选择哪一个？


➤ 较差的分类边界(如图)



➤ 较好的分类边界:

分类间隔 (margin) 尽可能大;

分类边界尽可能远离两类样本数据



➤ 最优分类边界:

能将两类无错误分开;

分类间隔(margin)最大

➤ H -----最优分类线;

➤ H_1, H_2 -----平行于 H 、且经过各类训练样本集中离 H 最近的训练样本

➤ 分类间隔(margin)----- H_1, H_2 之间的距离

➤ 推广到高维空间: 最优边界就变为最优超平面
(*optimal hyperplane*)

如何找到最优分类边界?

分类边界 $w \cdot x + b = 0$

判别函数 $g(x) = w \cdot x + b$

2. 线性SVM的分类间隔

线性可分训练样本集 $\{\mathbf{x}_i, y_i\} \quad i = 1, \dots, N \quad \mathbf{x}_i \in R^d$

类别标号 $y_i \in \{-1, 1\}$

d 维空间的线性判别函数 $g(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b$

判别函数归一化 $\begin{cases} \text{两类所有样本满足} & |g(\mathbf{x}_i)| \geq 1 \\ \text{离分类面最近样本} & |g(\mathbf{x}_i)| = 1 \end{cases}$

训练样本线性可分 $\begin{cases} g(\mathbf{x}_i) \geq 1 & \text{对于 } y_i = 1 \\ g(\mathbf{x}_i) \leq -1 & \text{对于 } y_i = -1 \end{cases}$


$$\Rightarrow y_i \cdot g(\mathbf{x}_i) \geq 1$$

$$\Rightarrow y_i \cdot [\mathbf{w} \cdot \mathbf{x}_i + b] - 1 \geq 0$$

最优分类面 H : $\mathbf{w} \cdot \mathbf{x} + b = 0$

正平面 H_1 : $\mathbf{w} \cdot \mathbf{x} + b = 1$


负平面 H_2 : $\mathbf{w} \cdot \mathbf{x} + b = -1$



设 $\begin{cases} \mathbf{x}^+ \text{ 为正平面 } H_1 \text{ 上任意点,} \\ \mathbf{x}^- \text{ 为负平面 } H_2 \text{ 上最接近 } \mathbf{x}^+ \text{ 的点, } \mathbf{x}^+ = \mathbf{x}^- + \lambda \mathbf{w} \end{cases}$

则 $\begin{cases} \text{正平面上} & \mathbf{w} \cdot \mathbf{x}^+ + b = 1 \\ \text{负平面上} & \mathbf{w} \cdot \mathbf{x}^- + b = -1 \\ \text{两平面间隔} & \text{margin} = \|\mathbf{x}^+ - \mathbf{x}^-\| = \|\lambda \mathbf{w}\| = \lambda \|\mathbf{w}\| \end{cases}$

$$\begin{cases} \text{正平面上: } \mathbf{w} \cdot \mathbf{x}^+ + b = 1 \\ \text{负平面上: } \mathbf{w} \cdot \mathbf{x}^- + b = -1 \\ \mathbf{x}^+ = \mathbf{x}^- + \lambda \mathbf{w} \end{cases}$$



$$\rightarrow \mathbf{w} \cdot (\mathbf{x}^- + \lambda \mathbf{w}) + b = 1$$

$$\rightarrow \mathbf{w} \cdot \mathbf{x}^- + b + \lambda \mathbf{w} \cdot \mathbf{w} = 1$$

$$\rightarrow -1 + \lambda \mathbf{w} \cdot \mathbf{w} = 1$$

$$\rightarrow \lambda = \frac{2}{\mathbf{w} \cdot \mathbf{w}} = \frac{2}{\|\mathbf{w}\|^2}$$

分类间隔 $margin = \|\mathbf{x}^+ - \mathbf{x}^-\| = \|\lambda \mathbf{w}\| = \frac{2}{\|\mathbf{w}\|}$

3. 线性SVM—目标函数的构造

最优分类边界

$$\left\{ \begin{array}{l} \text{分类间隔最大 } \text{margin} = \frac{2}{\|\mathbf{w}\|} \quad \Leftrightarrow \quad \text{使 } \|\mathbf{w}\| \text{ (或 } \|\mathbf{w}\|^2 \text{) 最小} \\ \text{训练样本线性可分 (均正确分类)} \quad \Leftrightarrow \quad y_i \cdot (\mathbf{w} \cdot \mathbf{x}_i + b) - 1 \geq 0 \\ \quad \quad \quad i = 1, 2, \dots, N \end{array} \right.$$

$$\phi(\mathbf{w}) = \frac{1}{2} \|\mathbf{w}\|^2 = \frac{1}{2} (\mathbf{w} \cdot \mathbf{w}) = \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

原始问题的目标函数 (线性可分问题的最大间隔法)

约束优化问题 (凸二次规划)

如何求解?

$$\left\{ \begin{array}{l} \min_{\mathbf{w}, b} \quad \phi(\mathbf{w}) = \frac{1}{2} (\mathbf{w} \cdot \mathbf{w}) \\ \text{s.t.} \quad y_i \cdot (\mathbf{w} \cdot \mathbf{x}_i + b) - 1 \geq 0 \quad i = 1, 2, \dots, n \end{array} \right.$$


4. 线性SVM—目标函数的求解

构造*Lagrange*辅助目标函数，将**原始问题**转化为**对偶问题**。

$$L(\mathbf{w}, b, \alpha) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) - \sum_{i=1}^N \alpha_i \{y_i \cdot [(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1\}$$

其中**非负***Lagrange*乘子向量 $\alpha = [\alpha_1 \quad \cdots \quad \alpha_N]^T$

显然： $L(\mathbf{w}, b, \alpha) \leq \frac{1}{2}(\mathbf{w} \cdot \mathbf{w})$



原始问题等价于：

$$\min_{\mathbf{w}, b} \max_{\alpha} L(\mathbf{w}, b, \alpha) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) - \sum_{i=1}^N \alpha_i \{y_i \cdot [(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1\}$$

$$\begin{aligned}
 L(\mathbf{w}, b, \boldsymbol{\alpha}) &= \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) - \sum_{i=1}^N \alpha_i \{y_i \cdot [(\mathbf{w} \cdot \mathbf{x}_i) + b] - 1\} \\
 &= \frac{1}{2}(\mathbf{w}^T \mathbf{w}) - \sum_{i=1}^N \alpha_i y_i \mathbf{w}^T \mathbf{x}_i - b \sum_{i=1}^N \alpha_i y_i + \sum_{i=1}^N \alpha_i
 \end{aligned}$$

$L(\mathbf{w}, b, \boldsymbol{\alpha})$ 在最优解处满足:

$$\left\{ \begin{array}{l} \text{条件 1} \quad \frac{\partial L(\mathbf{w}, b, \boldsymbol{\alpha})}{\partial \mathbf{w}} = 0 \quad \rightarrow \quad \mathbf{w} = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \\ \text{条件 2} \quad \frac{\partial L(\mathbf{w}, b, \boldsymbol{\alpha})}{\partial b} = 0 \quad \rightarrow \quad \sum_{i=1}^N \alpha_i y_i = 0 \end{array} \right.$$


该条件下, $L(\mathbf{w}, b, \alpha)$ 为

$$\begin{aligned} Q(\alpha) &= \sum_{i=1}^N \alpha_i + \frac{1}{2} (\mathbf{w}^T \mathbf{w}) - \mathbf{w}^T \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \\ &= \sum_{i=1}^N \alpha_i - \frac{1}{2} \mathbf{w}^T \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \\ &= \sum_{i=1}^N \alpha_i - \frac{1}{2} \left(\sum_{j=1}^N \alpha_j y_j \mathbf{x}_j \right)^T \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i \\ &= \sum_{i=1}^N \alpha_i - \frac{1}{2} \left(\sum_{j=1}^N \sum_{i=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_j^T \mathbf{x}_i \right) \\ &= \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{j=1}^N \sum_{i=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_j \cdot \mathbf{x}_i) \end{aligned}$$

对偶问题

$$\begin{aligned} \max_{\alpha} \quad & Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{j=1}^N \sum_{i=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_j \cdot \mathbf{x}_i) \\ \text{s.t.} \quad & \begin{cases} (1) \quad \sum_{i=1}^N \alpha_i y_i = 0 \\ (2) \quad \alpha_i \geq 0 \quad \text{对于 } i = 1, \dots, N \end{cases} \end{aligned}$$

等价形式



对偶问题


$$\begin{aligned} \min_{\alpha} \quad & W(\alpha) = \frac{1}{2} \sum_{j=1}^N \sum_{i=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_j \cdot \mathbf{x}_i) - \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \begin{cases} (1) \quad \sum_{i=1}^N \alpha_i y_i = 0 \\ (2) \quad -\alpha_i \leq 0 \quad \text{对于 } i = 1, \dots, N \end{cases} \end{aligned}$$

解得**非负**乘子向量的最优解: $\alpha^* = [\alpha_1^* \quad \cdots \quad \alpha_N^*]^T$

线性SVM中，判别函数的最优参数 w^* 、 b^* 的确定：

$$(1) \quad w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

$\alpha^* = [\alpha_1^* \quad \cdots \quad \alpha_N^*]^T$ 中多数分量为0



对 w^* 有贡献的只有占少数的非零 α_i^*

相应地，对应非零 α_i^* 的训练样本就称为**支持向量**(Support Vector)

作为支持向量的训练样本就位于 H_1, H_2 超平面。

线性SVM中，判别函数的最优参数 w^* 、 b^* 的确定：

(2) b^* 的确定


找到所有非零的 α_i^* 对应的支持向量，构成集合：

$$U = \{(\mathbf{x}_i, y_i) \mid (\mathbf{x}_i, y_i) \in \text{训练集 } T, \text{ 并且 } \alpha_i^* > 0\}$$

对于 $\forall (\mathbf{x}_i, y_i) \in U$ ，必有： $y_i = \mathbf{w}^* \cdot \mathbf{x}_i + b^*$

为了确保稳定性，取平均：

$$b^* = \frac{1}{\#U} \sum_{(\mathbf{x}_i, y_i) \in U} [y_i - \mathbf{w}^* \cdot \mathbf{x}_i]$$




$\#U$ ----集合 U 中元素数目(或表示为 $|U|$)

原始问题的目标函数(线性可分问题的最大间隔法)

$$\begin{cases} \min_{\mathbf{w}, b} \phi(\mathbf{w}) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) \\ s.t. \quad y_i \cdot (\mathbf{w} \cdot \mathbf{x}_i + b) - 1 \geq 0 \quad i = 1, 2, \dots, n \end{cases}$$

非负Lagrange乘子向量的最优解: $\alpha^* = [\alpha_1^* \quad \dots \quad \alpha_N^*]^T$



$$\text{最优分类边界 } (\mathbf{w}^* \cdot \mathbf{x}) + b^* = 0 \quad \begin{cases} \mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y_i \mathbf{x}_i \\ b^* = \frac{1}{\#U} \sum_{(\mathbf{x}_i, y_i) \in U} [y_i - \mathbf{w}^* \cdot \mathbf{x}_i] \\ U = \{(\mathbf{x}_i, y_i) \mid (\mathbf{x}_i, y_i) \in \text{训练集 } T, \text{ 并且 } \alpha_i^* > 0\} \end{cases}$$

$$\text{判别函数 } g(\mathbf{x}) = (\mathbf{w}^* \cdot \mathbf{x}) + b^* = \sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}) + b$$

$$f(\mathbf{x}) = \text{sgn}[(\mathbf{w}^* \cdot \mathbf{x}) + b^*] = \text{sgn}\left\{\sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}) + b^*\right\}$$

5. 利用线性SVM进行分类

对于未知类别的测试样本 \mathbf{x} ,

$$\text{若 } f(\mathbf{x}) = \text{sgn}\left[\left(\mathbf{w}^* \cdot \mathbf{x}\right) + b^*\right] = 1$$

则 \mathbf{x} 决策为第一类； 否则 \mathbf{x} 决策为第二类。

6.线性可分SVC算法

(1) 给定训练样本集 $T = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$

其中 $\mathbf{x}_i \in R^d, y_i \in \mathcal{Y} = \{1, -1\}, i = 1, \dots, N$

训练样本的
预处理

(2) 构造并求解凸二次规划问题

$$\begin{cases} \min_{\alpha} & W(\alpha) = \frac{1}{2} \sum_{j=1}^N \sum_{i=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_j \cdot \mathbf{x}_i) - \sum_{i=1}^N \alpha_i \\ s.t. & \begin{cases} (1) & \sum_{i=1}^N \alpha_i y_i = 0 \\ (2) & -\alpha_i \leq 0 \quad \text{对于 } i = 1, \dots, N \end{cases} \end{cases}$$

得解 $\alpha^* = [\alpha_1^*, \dots, \alpha_N^*]^T$

$$(3) \text{ 计算 } \mathbf{w}^* = \sum_{j=1}^N \alpha_j^* y_j \mathbf{x}_j$$

$$(4) \text{ 计算 } b^* = \frac{1}{\#U} \sum_{(\mathbf{x}_i, y_i) \in U} [y_i - \mathbf{w}^* \cdot \mathbf{x}_i]$$

其中 $U = \{(\mathbf{x}_i, y_i) \mid (\mathbf{x}_i, y_i) \in \text{训练集 } T, \text{ 并且 } \alpha_i^* > 0\}$

(5) 分类模型的使用:

$$g(\mathbf{x}) = (\mathbf{w}^* \cdot \mathbf{x}) + b^* = \sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}) + b^*$$

对于未知类别的测试样本 \mathbf{x} ,


待决策样本的预处理

$$\begin{cases} \text{若 } f(\mathbf{x}) = \text{sgn}[g(\mathbf{x})] = +1, & \text{则决策 } \mathbf{x} \text{ 为第1类} \\ \text{若 } f(\mathbf{x}) = \text{sgn}[g(\mathbf{x})] = -1, & \text{则决策 } \mathbf{x} \text{ 为第2类} \end{cases}$$

主要内容

- 1 两类别分类问题：线性可分情况
- 2 两类别分类问题：近似线性可分情况
- 3 多类别的线性SVM
- 4 应用举例

1.例 二维特征空间、两类别、线性不可分情况




适用：含噪声的训练样本；

容许对训练样本进行线性错分

2. 广义线性SVM—最优分类面的求取

(1) 问题描述

已知：训练样本集 $\{\mathbf{x}_i, y_i\}, i = 1, \dots, N$ $\mathbf{x}_i \in R^d$
类别标号 $y_i \in \{-1, 1\}$
估计：广义最优线性判别函数 $g(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b$



(2)目标函数的构造

折中：“最大分类间隔 + 训练样本集的最小错分程度”

归一化判别函数 $g(\mathbf{x}) = \mathbf{w} \cdot \mathbf{x} + b$

对所有训练样本，引入松弛变量 $\xi_i \geq 0, i = 1, \dots, N$

$$\text{for } i = 1, \dots, N \quad \begin{cases} g(\mathbf{x}_i) = \mathbf{w} \cdot \mathbf{x}_i + b \geq 1 - \xi_i & \text{若 } y_i = +1 \\ g(\mathbf{x}_i) = \mathbf{w} \cdot \mathbf{x}_i + b \leq -(1 - \xi_i) & \text{若 } y_i = -1 \end{cases}$$

$$\rightarrow y_i \cdot g(\mathbf{x}_i) + \xi_i \geq 1$$

$$\rightarrow y_i \cdot [\mathbf{w} \cdot \mathbf{x}_i + b] \geq 1 - \xi_i$$


目标函数构造的基本思想

$$\left\{ \begin{array}{ll} \text{分类间隔} margin = \frac{2}{\|w\|} \text{尽可能大} & \Leftrightarrow \frac{1}{2}(w \cdot w) \downarrow \\ \text{训练样本集的错分程度尽可能低} & \Leftrightarrow \sum_{i=1}^N \xi_i \downarrow \end{array} \right.$$

原始目标函数

松弛因子向量 $\xi = [\xi_1 \ \cdots \ \xi_N]^T$

C - SVC (标准SVC)


$$\begin{array}{ll} \min_{w, \xi, b} & \phi(w, \xi, b) = \frac{1}{2}(w \cdot w) + \mathbf{C} \left(\sum_{i=1}^N \xi_i \right) \\ s.t. & \begin{cases} -[y_i \cdot (w \cdot x_i + b) - 1 + \xi_i] \leq 0 \\ -\xi_i \leq 0 \end{cases} \quad i = 1, 2, \dots, N \end{array}$$

C > 0 -- 模型的超参数，控制错分样本的惩罚程度

(3)目标函数的求解

构造**Lagrange**辅助目标函数，将**原始问题**转化为**对偶问题**.

$$\left\{ \begin{array}{l} \min \quad L(\mathbf{w}, b, \xi; \boldsymbol{\alpha}, \boldsymbol{\mu}) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) + C \left(\sum_{i=1}^N \xi_i \right) \\ \quad \quad \quad - \sum_{i=1}^N \alpha_i \{ y_i \cdot [\mathbf{w} \cdot \mathbf{x}_i + b] - 1 + \xi_i \} - \sum_{i=1}^N \mu_i \xi_i, \\ \alpha_i \geq 0, \quad i = 1, 2, \dots, N \\ \mu_i \geq 0, \quad i = 1, 2, \dots, N \end{array} \right.$$

其中**非负**Lagrange乘子向量 $\begin{cases} \boldsymbol{\alpha} = [\alpha_1 & \cdots & \alpha_N]^T \\ \boldsymbol{\mu} = [\mu_1 & \cdots & \mu_N]^T \end{cases}$

$$\text{显然: } L(\mathbf{w}, b, \xi; \boldsymbol{\alpha}, \boldsymbol{\mu}) \leq \phi(\mathbf{w}, \xi, b) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) + C \left(\sum_{i=1}^N \xi_i \right)$$

原始问题等价于： $\min_{\mathbf{w}, b, \xi} \max_{\boldsymbol{\alpha}, \boldsymbol{\mu}} L(\mathbf{w}, b, \xi; \boldsymbol{\alpha}, \boldsymbol{\mu})$

原始目标函数

C - SVC (标准SVC)


$$\begin{aligned} \min_{\mathbf{w}, \xi, b} \quad & \phi(\mathbf{w}, \xi, b) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) + \mathbf{C} \left(\sum_{i=1}^N \xi_i \right) \\ \text{s.t.} \quad & \begin{cases} -[y_i \cdot (\mathbf{w} \cdot \mathbf{x}_i + b) - 1 + \xi_i] \leq 0 \\ -\xi_i \leq 0 \end{cases} \quad i = 1, 2, \dots, N \end{aligned}$$

对偶目标函数

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{j=1}^N \sum_{i=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_j \cdot \mathbf{x}_i) \\ \text{s.t.} \quad & \begin{cases} (1) \quad \sum_{i=1}^N \alpha_i y_i = 0 \\ (2) \quad 0 \leq \alpha_i \leq C, \quad i = 1, \dots, N \end{cases} \end{aligned}$$

解得 $\boldsymbol{\alpha}^* = [\alpha_1^*, \dots, \alpha_N^*]^T$

样本的错分与正确分类



- — 第一类样本
- × — 第二类样本
- ⊙ ⊙ — 一边界支持向量
- ⊠ ⊠ — 错分支持向量

训练样本集 T 的划分 基于 $\alpha^* = [\alpha_1^* \cdots \alpha_N^*]^T$ 中各分量取值的三种可能划分

- $\alpha_i^* = 0$ 训练样本 x_i 为**非支持向量**
- $0 < \alpha_i^* < C$ 训练样本 x_i 为**边界支持向量** (位于 H_1, H_2 超平面)
- $\alpha_i^* = C$ 训练样本 x_i 为**错分支持向量**

训练样本集 = { **非支持向量** } \cup { **边界支持向量** } \cup { **错分支持向量** }

广义线性SVM中，判别函数的最优参数 w^* 、 b^* 的确定：

$$A. \quad w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

对 w^* 有贡献的只有占少数的非零 α_i^*

对应非零 α_i^* 的训练样本就称为**支持向量**(*Support Vector*)

B. b^* 的确定

找到所有**边界支持向量**，构成集合：

$$U = \{ (x_i, y_i) \mid (x_i, y_i) \in \text{训练集 } T, \text{ 并且 } 0 < \alpha_i^* < C \}$$


对于 $\forall (x_i, y_i) \in U$ ，必有： $y_i = w^* \cdot x_i + b^*$

为了确保稳定性，取平均：

$$b^* = \frac{1}{\#U} \sum_{(x_i, y_i) \in U} [y_i - w^* \cdot x_i]$$

$\#U$ ----集合 U 中元素数目(或表示为 $|U|$)

(4) 广义线性SVM的判别函数



广义最优分类决策函数：

$$f(\mathbf{x}) = \text{sgn} \left[\left(\mathbf{w}^* \cdot \mathbf{x} \right) + b^* \right] = \text{sgn} \left\{ \sum_{i=1}^N \alpha_i^* y_i \left(\mathbf{x}_i \cdot \mathbf{x} \right) + b^* \right\}$$

广义线性SVM (C - SVC) 原始问题的目标函数

$$\begin{aligned} \min_{\mathbf{w}, \xi, b} \quad & \phi(\mathbf{w}, \xi, b) = \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) + C \left(\sum_{i=1}^N \xi_i \right) \\ \text{s.t.} \quad & \begin{cases} -[y_i \cdot (\mathbf{w} \cdot \mathbf{x}_i + b) - 1 + \xi_i] \leq 0 \\ -\xi_i \leq 0 \end{cases} \quad i = 1, 2, \dots, N \end{aligned}$$

非负Lagrange乘子向量的最优解: $\boldsymbol{\alpha}^* = [\alpha_1^* \quad \cdots \quad \alpha_N^*]^T$

$$\text{最优分类边界 } (\mathbf{w}^* \cdot \mathbf{x}) + b^* = 0 \quad \begin{cases} \mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y_i \mathbf{x}_i \\ b^* = \frac{1}{\#U} \sum_{(\mathbf{x}_i, y_i) \in U} [y_i - \mathbf{w}^* \cdot \mathbf{x}_i] \\ U = \{(\mathbf{x}_i, y_i) \mid (\mathbf{x}_i, y_i) \in \text{训练集 } T, \text{ 并且 } 0 < \alpha_i^* < C\} \end{cases}$$

$$\text{判别函数 } g(\mathbf{x}) = (\mathbf{w}^* \cdot \mathbf{x}) + b^* = \sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}) + b$$

$$f(\mathbf{x}) = \text{sgn}[(\mathbf{w}^* \cdot \mathbf{x}) + b^*] = \text{sgn} \left\{ \sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}) + b^* \right\}$$

[线性C-SVC算法]

(1) 给定训练样本集 $T = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$,

训练样本的
预处理

其中 $\mathbf{x}_i \in R^d, y_i \in \mathcal{Y} = \{1, -1\}, i = 1, \dots, N$

(2) 选择适当的惩罚参数 C [问题: 如何选择参数 C]

(3) 构造并求解凸二次规划问题

$$\begin{cases} \min_{\alpha} & \frac{1}{2} \sum_{j=1}^N \sum_{i=1}^N \alpha_i \alpha_j y_i y_j (\mathbf{x}_j \cdot \mathbf{x}_i) - \sum_{i=1}^N \alpha_i \\ s.t. & \begin{cases} (1) & \sum_{i=1}^N \alpha_i y_i = 0 \\ (2) & 0 \leq \alpha_i \leq C \quad \text{对于 } i = 1, \dots, N \end{cases} \end{cases}$$

得解 $\boldsymbol{\alpha}^* = [\alpha_1^*, \dots, \alpha_N^*]^T$

(4) 估计 $\mathbf{w}^* = \sum_{i=1}^N \alpha_i^* y_i \mathbf{x}_i$

(5) 估计 b^*

找到所有**边界支持向量**，构成集合：

$$U = \{(\mathbf{x}_i, y_i) \mid (\mathbf{x}_i, y_i) \in \text{训练集 } T, \text{ 并且 } 0 < \alpha_i^* < C\}$$

对于 $\forall (\mathbf{x}_i, y_i) \in U$ ，必有： $y_i = \mathbf{w}^* \cdot \mathbf{x}_i + b^*$

$$b^* = \frac{1}{\#U} \sum_{i \in U} \left[y_i - \sum_{j=1}^N \alpha_j^* y_j (\mathbf{x}_j \cdot \mathbf{x}_i) \right]$$

(6) 分类模型的使用： $g(\mathbf{x}) = (\mathbf{w}^* \cdot \mathbf{x}) + b^* = \sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}) + b^*$

对于未知类别的测试样本 \mathbf{x} ,

$$\begin{cases} \text{若 } f(\mathbf{x}) = \text{sgn}[g(\mathbf{x})] = +1, & \text{则决策 } \mathbf{x} \text{ 为第1类} \\ \text{若 } f(\mathbf{x}) = \text{sgn}[g(\mathbf{x})] = -1, & \text{则决策 } \mathbf{x} \text{ 为第2类} \end{cases}$$

待决策样本
的预处理

第二部分

基于两类别SVC模型的多类别分类

主要内容

1. 多类问题描述

2 基于两类SVC的方法

SVM主要是解决两类问题；实际应用以多类问题为主

问题：

如何利用已有的两类SVM模型，解决多类别的分类问题？

M 类分类问题描述：

给定：训练样本集 $T = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$,

其中 $\mathbf{x}_i \in R^d, i = 1, 2, \dots, N$

$y_i \in \mathcal{Y} = \{1, 2, \dots, M\}$

要求：寻找 R^d 空间上的决策函数 $f(\mathbf{x}): R^d \rightarrow \mathcal{Y}$;
用以推断任意输入 \mathbf{x} 对应的输出 y .

主要内容

1. 多类问题描述

2. 几个典型的基于两类SVC的方法

2.1 成对分类(one verse one, one against one)

2.2 一类对余类(one verse the rest)

2.3 有向无环图

M类分类模型的算法描述(成对分类法):

(1) 给定标准训练样本集 $T = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$,

其中 $\mathbf{x}_i \in R^d$, $y_i \in \mathcal{Y} = \{1, 2, \dots, M\}$ $i = 1, 2, \dots, N$

(2) 训练阶段:

基于SVC, 训练 $C_M^2 = \frac{M(M-1)}{2}$ 个两类SVC:

对于所有 $(i, j) \in \{(i, j) | i < j, i, j = 1, \dots, M\}$, 进行如下运算:

从训练集中分别抽取对应 $y = i$ 和 $y = j$ 的训练样本, 分别作为正样本点和负样本点, 构成训练集 $T_{i \text{ 对 } j}$;

由 $T_{i \text{ 对 } j}$ 求解两类分类问题的SVC $_{i \text{ 对 } j}$, 得到实值函数 $g_{i \text{ 对 } j}(\mathbf{x})$, 以及用于判定任意输入 \mathbf{x} 属于第 i 或 j 类的决策函数 $f_{i \text{ 对 } j}(\mathbf{x})$

$$f_{i \text{ 对 } j}(\mathbf{x}) = \begin{cases} i & \text{若 } g_{i \text{ 对 } j}(\mathbf{x}) > 0 \\ j & \text{若 } g_{i \text{ 对 } j}(\mathbf{x}) < 0 \end{cases}$$

(3) 分类阶段:

构建针对上述 $\frac{M(M-1)}{2}$ 个两类 *SVC* 的**投票表决器**;

对于未知输入 x , 考虑上述所有的 *SVC* 的判决结果, 某 *SVC* 判定 x 属于第 i 个类别, 相应的第 i 类的**表决器票数增1**。

票数最多的**表决器**对应的类别, 即为 x 的最终判决类别。

LIBSVM 基于“成对分类”实现多类问题的分类; 得票数最多类别不止一个时, 将 x 判决为对应**最高票数的最小类别**。

实际使用时, 应结合具体问题做适当处理。

主要内容

1. 多类问题描述

2. 基于两类SVC的方法

2.1 成对分类(one verse one, one against one)

2.2 一类对余类(one verse the rest)

2.3 有向无环图

算法描述

(1) 给定 M 类分类的标准训练样本集

$$\mathbf{T} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$$

其中 $\mathbf{x}_i \in R^d$, $y_i \in \mathcal{Y} = \{1, 2, \dots, M\}$ $i = 1, 2, \dots, N$

(2) 训练: 对于 $j = 1, \dots, M$, 进行如下运算:

从训练集 \mathbf{T} 中分别抽取对应 j 和其余 $M-1$ 类的训练点, 分别作为**正类**和**负类**样本点, 用于训练第 j 个两类分类问题的 $SVC_{j\text{对其它}}$, 得到 $g_{j\text{对其它}}(\mathbf{x})$

(3) 决策: 判定输入 \mathbf{x} 属于第 J 类.

$$\text{其中, } J = \arg \max_j g_{j\text{对其它}}(\mathbf{x})$$

主要内容

0. 多类问题描述

1. 基于两类SVC的方法

1.1 成对分类 (one verse one, one against one)

1.2 一类对余类 (one verse the rest)

1.3 有向无环图

Directed Acyclic Graph Support Vector Machine (DAGSVM)

有向无环图-算法(1)

(1) 给定 M 类分类的训练样本集 $T = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$

其中 $\mathbf{x}_i \in R^d$, $y_i \in \mathcal{Y} = \{1, 2, \dots, M\}$ $i = 1, 2, \dots, N$

(2) 训练 $\frac{M(M-1)}{2}$ 个两类SVC.

对于所有 $(i, j) \in \{(i, j) | i < j, i, j = 1, \dots, M\}$, 进行如下运算:

从训练集中分别抽取对应 $y = i$ 和 $y = j$ 的训练点, 分别作为正样本点和负样本点, 构成训练集 $T_{i \text{对} j}$; 由 $T_{i \text{对} j}$ 求解SVC $_{i \text{对} j}$, 得到实值函数 $g_{i \text{对} j}(\mathbf{x})$, 以及用于判定任意输入 \mathbf{x} 属于第 i 或 j 类的决策

$$\text{函数 } f_{i \text{对} j}(\mathbf{x}) \quad f_{i \text{对} j}(\mathbf{x}) = \begin{cases} i & g_{i \text{对} j}(\mathbf{x}) > 0 \\ j & g_{i \text{对} j}(\mathbf{x}) < 0 \end{cases}$$

有向无环图-算法(2)

(3)构建二叉树.

使之具有： $\frac{M(M-1)}{2}$ 个内部节点， M 个叶子：

每个内部节点对应一个两类SVC；

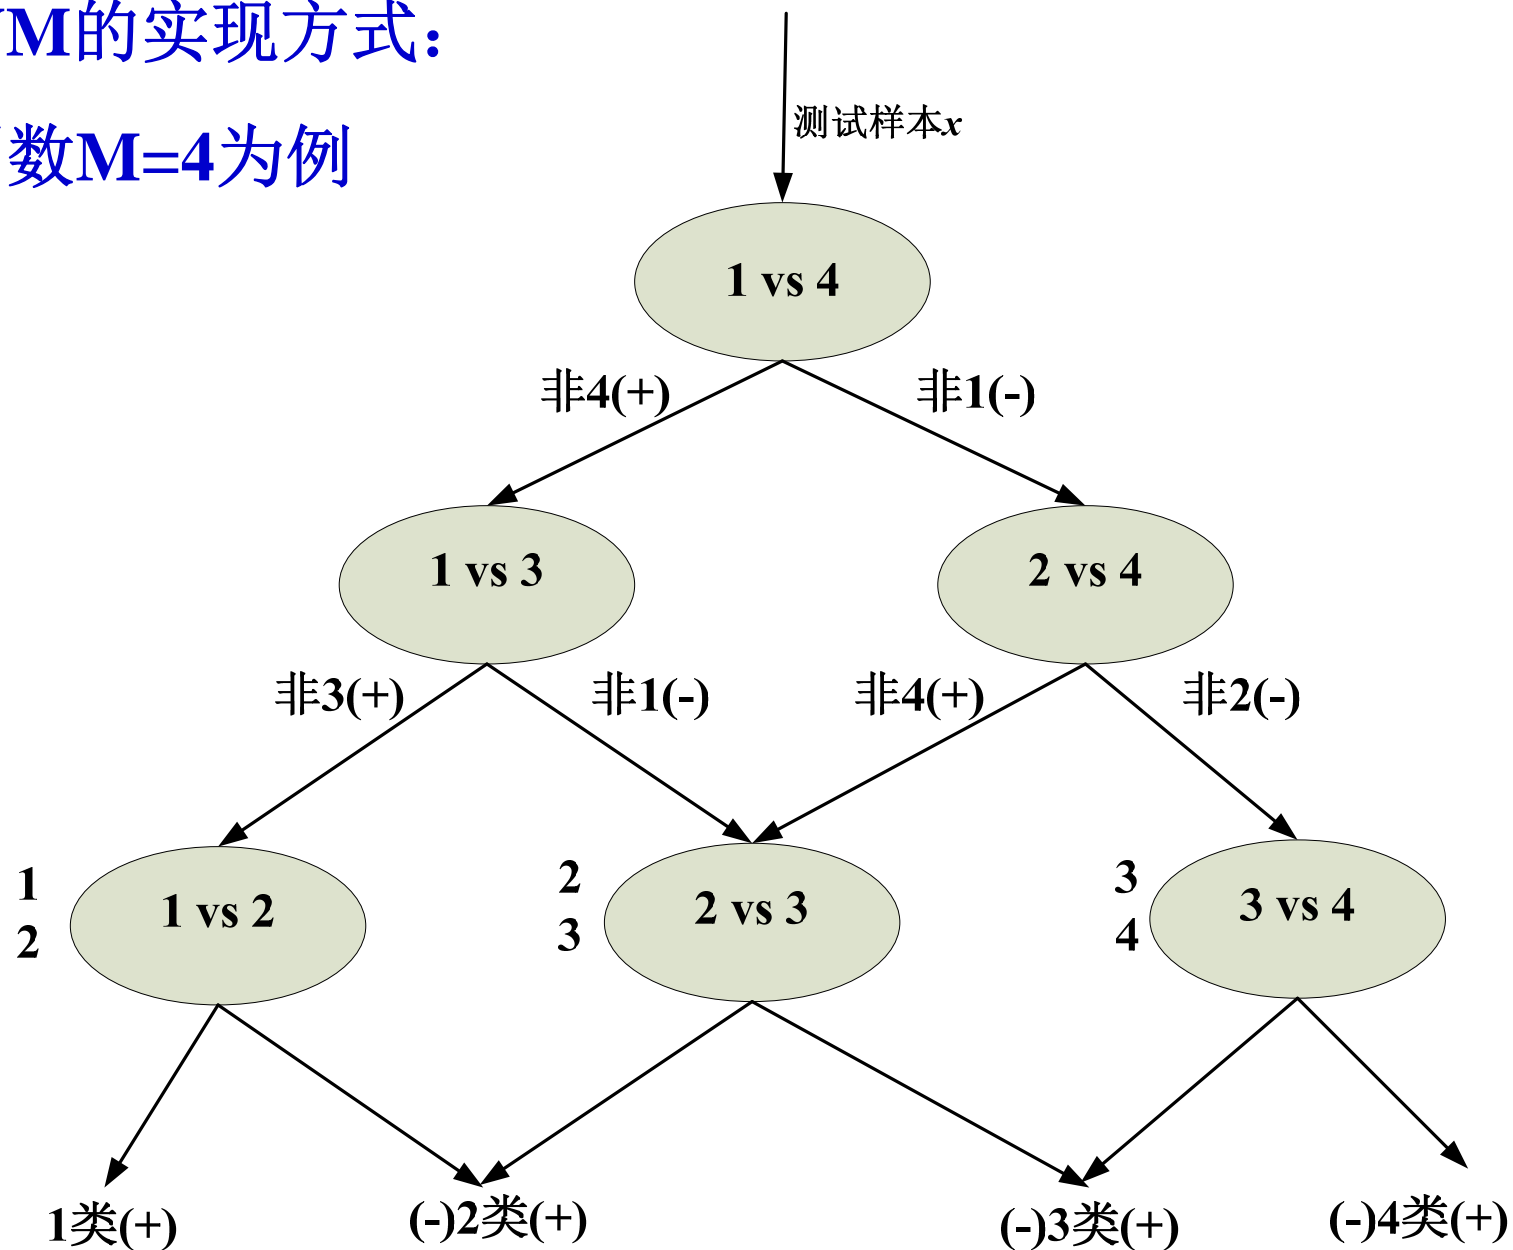
叶子对应最终的类别。

(4)分类. 判定输入 x 的所属类别,从图的根节点开始输入 x ,
根据每个节点的输出决定左侧或者右侧路径,
一直到达叶子,即可确定所属类别。

每个 x 只需访问 $M-1$ 个节点。

LIBSVM的实现方式:

以类别数M=4为例



第三部分

两类别的核SVC (非线性SVC)

主要内容

1 核SVM

线性SVM回顾

非SVM基本思想

变换空间的最优分类面

核函数作为内积的条件

几种典型核函数

核函数形式的选取

核函数的构造

C-SVC算法描述

2 应用举例

(1) 线性SVC的回顾

线性SVM: 训练样本线性可分

原始目标函数:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 = \frac{1}{2} (\mathbf{w} \cdot \mathbf{w}) \\ \text{s.t.} \quad & y_i \cdot [\mathbf{w} \cdot \mathbf{x}_i + b] - 1 \geq 0 \\ & i = 1, 2, \dots, N \end{aligned}$$

广义线性SVM: 训练样本线性不可分


原始目标函数:

$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2} (\mathbf{w} \cdot \mathbf{w}) + C \left(\sum_{i=1}^N \xi_i \right) \\ \text{s.t.} \quad & y_i \cdot [\mathbf{w} \cdot \mathbf{x}_i + b] - 1 + \xi_i \geq 0 \\ & \xi_i \geq 0 \quad i = 1, 2, \dots, N \end{aligned}$$

最优分类函数:

$$f(\mathbf{x}) = \text{sgn} \left[(\mathbf{w}^* \cdot \mathbf{x}) + b^* \right] = \text{sgn} \left\{ \sum_{i=1}^N \alpha_i^* y_i (\mathbf{x}_i \cdot \mathbf{x}) + b^* \right\}$$

其中 对应 $\alpha_i^* = 0$ 的 \mathbf{x}_i 为支持向量



最优分类面: $\mathbf{w}^* \cdot \mathbf{x} + b^* = 0$

分类函数只涉及内积运算

(1) 线性SVC的回顾

线性SVM存在局限性：

➤ 灵活性差

➤ 很多实际问题往往不是线性可分的

。 。 。

线性不可分情况的两种处理方式

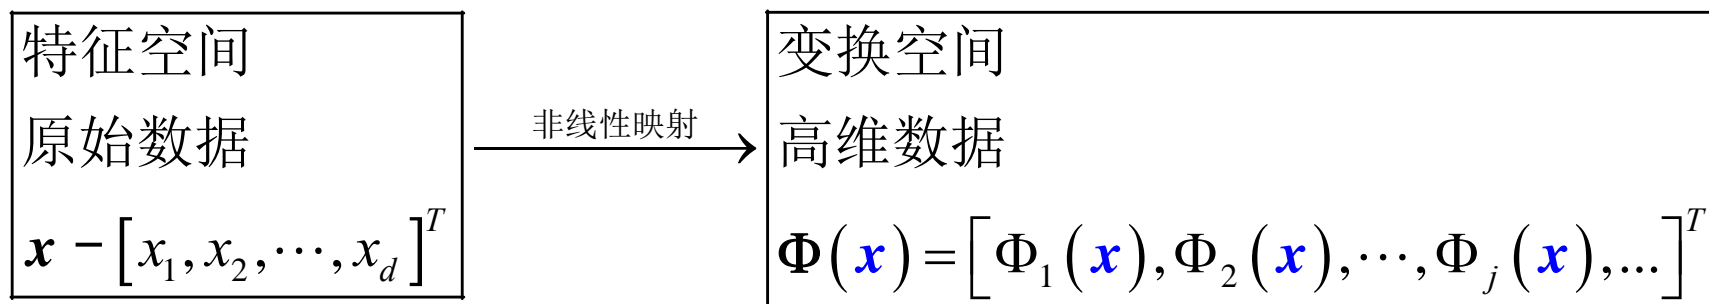
方式1：引入松弛项

➔ 广义线性SVM

方式2： 是否在其它空间线性可分？ ➔ 非线性SVM

(2) 非线性SVM思想

- 通过非线性映射，将原始数据由低维特征空间变换到高维空间(可能是无限维)



- 在高维变换空间中设计线性SVM，寻求最优分类面
- 非线性变换是通过定义适当的内积函数隐式实现的

(3) 高维变换空间中的最优分类面

➤ 对于非线性SVM,将原始数据映射到高维变换空间后,
变换空间的线性SVM:

原始问题:

$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2}(\mathbf{w} \cdot \mathbf{w}) + C \left(\sum_{i=1}^N \xi_i \right) \\ \text{s.t.} \quad & y_i \cdot [\mathbf{w} \cdot \Phi(\mathbf{x}_i) + b] - 1 + \xi_i \geq 0 \\ & \xi_i \geq 0 \quad i = 1, 2, \dots, N \end{aligned}$$

对偶问题:

$$\begin{aligned} \max_{\alpha} \quad & Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{j=1}^N \sum_{i=1}^N \alpha_i \alpha_j y_i y_j (\Phi(\mathbf{x}_j) \cdot \Phi(\mathbf{x}_i)) \\ \text{s.t.} \quad & \begin{cases} (1) \quad \sum_{i=1}^N \alpha_i y_i = 0 \\ (2) \quad 0 \leq \alpha_i \leq C \quad \text{对于所有 } i \end{cases} \end{aligned}$$

最优分类函数

$$\begin{aligned} f(\mathbf{x}) &= \text{sgn} \left[\left(\mathbf{w}^* \cdot \Phi(\mathbf{x}) \right) + b^* \right] \\ &= \text{sgn} \left\{ \sum_{i=1}^N \alpha_i^* y_i \left(\Phi(\mathbf{x}_i) \cdot \Phi(\mathbf{x}) \right) + b^* \right\} \end{aligned}$$

最优分类面

$$\left(\mathbf{w}^* \cdot \Phi(\mathbf{x}) \right) + b^* = 0$$

其中： $\mathbf{w}^* = \sum_{i=1}^n \alpha_i^* y_i \Phi(\mathbf{x}_i)$

目标函数与最优分类函数涉及内积运算，内积形式以核函数表示：

$$K(\mathbf{x}_i, \mathbf{x}_j) = \Phi(\mathbf{x}_i) \cdot \Phi(\mathbf{x}_j) = \sum_l \Phi_l(\mathbf{x}_i) \Phi_l(\mathbf{x}_j)$$

kernel trick

核函数形式的非线性SVM：

目标函数：

$$\Phi(\mathbf{x}_i) \cdot \Phi(\mathbf{x}_j)$$

$$\max_{\alpha} \quad Q(\alpha) = \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{j=1}^n \sum_{i=1}^n \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j)$$

$$s.t. \quad \begin{cases} (1) \quad \sum_{i=1}^n \alpha_i y_i = 0 \\ (2) \quad 0 \leq \alpha_i \leq C \quad \text{对于所有 } i \end{cases}$$

$$\text{最优分类函数: } f(\mathbf{x}) = \text{sgn} \left\{ \sum_{i=1}^n \alpha_i^* y_i K(\mathbf{x}_i, \mathbf{x}) + b^* \right\}$$

对于函数 $k(\mathbf{x}, \mathbf{y}) = (1 + x_1 y_1 + x_2 y_2)^2$

考虑如下变换：

$$\phi(\mathbf{x}) = \phi\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = (1, \sqrt{2}x_1, \sqrt{2}x_2, x_1^2, x_2^2, \sqrt{2}x_1x_2)^T$$

$$\phi(\mathbf{y}) = \phi\left(\begin{bmatrix} y_1 \\ y_2 \end{bmatrix}\right) = (1, \sqrt{2}y_1, \sqrt{2}y_2, y_1^2, y_2^2, \sqrt{2}y_1y_2)^T$$

则变换后的内积计算： $\phi(\mathbf{x}) \cdot \phi(\mathbf{y})$

若直接用函数计算，则： $k(\mathbf{x}, \mathbf{y}) = (1 + x_1 y_1 + x_2 y_2)^2 = \phi(\mathbf{x}) \cdot \phi(\mathbf{y})$

无需知道变换函数 $\phi(\bullet)$ 的显式形式，即可借助**核函数**，
完成等价于变换空间内积运算，这就是**核技巧**。— *kernel trick*

(4)函数作为内积核函数的条件—Mercer条件

➤ 统计学习理论告诉我们：只要函数满足Mercer条件，就可以作为内积核函数使用。

若 $K(x_1, x_2) = K(x_2, x_1)$ ，则 $K(\bullet, \bullet)$ 是对称函数

定理[*Mercer's condition*]

对于任意的对称函数 $K(x, x')$ ，它是某个变换空间中的内积运算的充要条件是

$$\iint K(x, x') \varphi(x) \varphi(x') dx dx' \geq 0 \quad \text{对于任意的} \varphi(x) \neq 0$$

且 $\int \varphi^2(x) dx < \infty$ 均成立。

相应的 $K(x, x')$ 为Mercer核。

(5) SVM常用的核函数形式

(I) 多项式核函数 $K(\mathbf{x}, \mathbf{x}') = [(\mathbf{x} \cdot \mathbf{x}') + 1]^q$

q 阶多项式SVM

特例 线性内积函数 $K(\mathbf{x}, \mathbf{x}_i) = (\mathbf{x} \cdot \mathbf{x}_i)$

(II) RBF $K(\mathbf{x}, \mathbf{x}') = \exp \left\{ -\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{\sigma^2} \right\} = \exp \left\{ -\gamma \|\mathbf{x} - \mathbf{x}'\|^2 \right\}$

RBF-SVM

(III) S型内积函数 $K(\mathbf{x}, \mathbf{x}') = \tanh(\nu(\mathbf{x} \cdot \mathbf{x}') + c)$

SVM为3层感知器神经网络

只有部分 ν , c 值满足**MERCER**条件

(6) 核函数类型及核函数参数的选择

基本原则：由线性至非线性，由简单至复杂。

- 若原始特征空间的维数 \gg 样本数目，可采用线性核函数
- 非线性核函数，通常使用RBF函数，理由：
 - RBF函数可以将样本非线性地映射到更高维(无限维)空间中。Sigmoid核函数取某些特定参数时，性能和RBF相同。
 - RBF函数的参数只有一个。
 - RBF函数的数值限制条件少。RBF函数取值限制在0和1之间，而多项式核函数的值可能会趋于不定值或零值，且幂值更高；Sigmoid核函数在取某些参数值时则可能无效。
 - 应先尝试较大窗宽的RBF函数，窗宽越大，越接近线性

(6) C -支持向量分类机算法 (C -SVC)

STEP1 给定训练样本集 $T = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$,

其中 $\mathbf{x}_i \in R^d$, 类别标号 $y_i \in \mathcal{Y} = \{-1, 1\}$

$i = 1, 2, \dots, n$

STEP2 选取适当核函数 $K(x, x')$ 及惩罚参数 $C > 0$

$\left\{ \begin{array}{l} \text{核函数形式的确定} \\ \text{核函数的参数及惩罚参数 } C \text{ 的确定} \end{array} \right.$

STEP3 构造并求解凸二次规划问题

$$\begin{array}{ll} \min_{\alpha} & Q(\alpha) = \frac{1}{2} \sum_{j=1}^n \sum_{i=1}^n \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j) - \sum_{i=1}^n \alpha_i \\ s.t. & \begin{cases} (1) & \sum_{i=1}^n \alpha_i y_i = 0 \\ (2) & 0 \leq \alpha_i \leq C \quad i = 1, 2, \dots, n \end{cases} \end{array}$$

得解 $\alpha^* = [\alpha_1^*, \dots, \alpha_n^*]^T$

STEP4 计算 \mathbf{b}^* :

从 $\boldsymbol{\alpha}^* = [\alpha_1^*, \dots, \alpha_n^*]^T$ 中选取 $\alpha_j^* \in (0, C)$, 计算

$$\mathbf{b}^* = \mathbf{y}_j - \sum_{i=1}^n \alpha_i^* y_i k(\mathbf{x}_i, \mathbf{x}_j)$$

为了确保稳定性, 取平均运算, 其中 U 为所有位于 $(0, C)$

的 α_i^* 下标集合。

$$\mathbf{b}^* = \frac{1}{\#U} \sum_{i \in U} \left[y_i - \sum_{j=1}^n \alpha_j^* y_j k(\mathbf{x}_i, \mathbf{x}_j) \right]$$

STEP5 构造分划超平面 $(\boldsymbol{\omega}^* \cdot \boldsymbol{\phi}(\mathbf{x})) + \mathbf{b}^* = 0$, 得决策函数:

$$f(\mathbf{x}) = \text{sgn}\{g(\mathbf{x})\}$$

其中 $g(\mathbf{x}) = \sum_{i=1}^n \alpha_i^* y_i K(\mathbf{x}_i, \mathbf{x}) + \mathbf{b}^*$

参数寻优方法

以 **C - SVC** 为例，假定核函数为 $K(\mathbf{x}, \mathbf{x}_i) = \exp\left\{-\gamma \|\mathbf{x} - \mathbf{x}_i\|^2\right\}$, $\gamma > 0$

进行参数 (**C**, γ) 的优选，如：

方法1: "grid searching" + "k - fold cross - validation"

LIB - SVM 的代码实现

方法2: "遗传算法" + "k - fold cross - validation"

关于待求参数进行染色体编码；

以识别率作为贴近度函数

方法3: "粒子群优化算法" + "k - fold cross - validation"

参数选择

(1) 系统性能评价----"k - fold cross - validation"

A.训练集划分. 将 n 个训练样本组成的训练集, 随机分成 k 组规模一致且互不相交子集, 即 k -折: S_1, \dots, S_k
($k = n$ 时, 称做留一法, *leave - one - out, LOO*)

B.训练与测试. for : $i = 1, \dots, k$

{ 取 S_i 为**测试子集**, 其它 $k-1$ 个子集共同组成**训练子集**;
由**训练子集**训练, 得到分类器判别决策函数;
对**测试子集** S_i 测试, 统计错分样本数目 l_i

C.误差估计.

基于 k -折交叉验证的误差估计 $\frac{1}{k} \sum_{i=1}^k \frac{l_i}{\#S_i}$

基于留一法的误差估计 $\frac{\sum_{i=1}^n l_i}{n}$

参数选择

(2) 参数的搜索----"grid-search"

首先，选定一组 (C, γ) 的范围，比如
$$\begin{cases} \log_2 C: & -5 \sim 15 \\ \log_2 \gamma: & -15 \sim 3 \end{cases}$$

为避免时间消耗，可采用**coarse-to-fine**的搜索策略。

first, loose grid-search----目的：识别较好的 $grid$

如：搜索步长 $(step_{\log_2 C}, step_{\log_2 \gamma}) = (2, 2)$

找到具有最小" k -折交叉验证的误差"的 $grid$ 对应的 (C_0, γ_0)

then, fine grid-search----在 (C_0, γ_0) 邻域，获取更好的 (C, γ)

减小搜索步长，在更小的区域内精细搜索。

如：搜索步长 $(step_{\log_2 C}, step_{\log_2 \gamma}) = (0.25, 0.25)$

每一组可能的 (C, γ) ，都对应一次性能评价（误差，或者准确率）


参数选择

网格搜索法的优点:


该方法比较简单，易操作；可以同时搜索多个参数。最终获取的是使分类准确率达到最优的参数组合。

该方法的缺点:

需反复进行多次训练，计算量较大。



Loose grid search on $C = 2^{-5}, 2^{-3}, \dots, 2^{15}$ and $\gamma = 2^{-15}, 2^{-13}, \dots, 2^3$.



Fine grid-search on $C = 2^1, 2^{1.25}, \dots, 2^5$ and $\gamma = 2^{-7}, 2^{-6.75}, \dots, 2^{-3}$.

主要内容

1 核SVM

线性SVM回顾

非SVM基本思想

变换空间的最优分类面

核函数作为内积的条件

几种典型核函数

核函数形式的选取

核函数的构造

C-SVC算法描述


2 应用举例

例： A Nonlinear Kernel Application


Checkerboard Training Set: 1000 Points in R^2

Separate 486 Asterisks(*) from 514 Dots(.)

两类问题




Polynomial Kernel:



例.两类问题--两组二维合成数据分类

图中： 划叉样本点----错分样本；
 被圈样本点----支持向量

核函数---- $q=2$ 阶多项式核函数




例：两类问题。

➤ 核函数：高斯径向基核函数

➤ 训练样本

➤ 支持向量

➤ 决策边界



例：多类问题

美国邮政标准 手写库的数字 识别对比实验

部分样本

- 可识别性比较差
- 样本16*16点阵
256维特征

训练集：7300个

测试集：2000个

2601496357146371037214497
1105711129781102860028870
3301033010290602810029012
9405290672980129650299055
5101292018032-70124431064
1161176057188600158701899
1157557212570688327499516
9950572001536272203242370
3507271272315393053880319
1371914119129192551917014
1011913485726803226414186
6359720299299722510046701
3084111591010615406103631
1064111030475262009979966
8912056708557131427955460
2018730187112993089970984
0109707597331972015519055
1075518255182814358090963
1787521655460354603546055
18255108503047520439401

数字识别实质为“10类问题”的分类

第1. 人工及传统方法分类的性能比较

分类器	测试错误率
人工分类	2.5%
决策树C4.5	16.2%
最好的两层神经网络	5.9%
LeNet1(五层神经网络)	5.1%

第2.基于核SVM的数字识别

(1) 多项式核函数 $K(\mathbf{x}, \mathbf{x}_i) = \left[\frac{1}{256} (\mathbf{x} \cdot \mathbf{x}_i) \right]^q$, 参数 $q = 1, \dots, 6$

(2) 径向基核函数 $K(\mathbf{x}, \mathbf{x}_i) = \exp \left\{ -\frac{|\mathbf{x} - \mathbf{x}_i|^2}{256\sigma^2} \right\}$

参数 $\sigma = 0.1 \sim 4.0$

(3) *Sigmoid*型核函数

$$K(\mathbf{x}, \mathbf{x}_i) = \tanh \left(\frac{b(\mathbf{x} \cdot \mathbf{x}_i)}{256} - c \right) \quad b, c \text{ 参数}$$

第2：基于核SVM的数字识别

支持向量机类型	内积函数中的参数	支持向量个数	测试错误率
多项式内积	$q=3$	274	4.0%
径向基函数内积	$\sigma^2=0.3$	291	4.1%
Sigmoid 内积	$b=2, c=1$	254	4.2%

本例结论

- SVM方法比传统方法更有优势
- 不同的SVM方法可以得到性能相近的结果
- SVM分类器所用支持向量数量相对于训练样本总数很少
- 支持向量本身对不同核具有一定的不敏感性

SVM的软件实现

➤ SVM 资源及实现:

<http://www.support-vector.net/index.html>

<http://www.support-vector.net/software.html>

<http://www.kernel-machines.org/>

<http://www.kernel-machines.org/software.html>

➤ 典型工具箱: c 或 MATAB

SVM^{light}

SVM^{Torch}

LIBSVM

...

思考：哪些因素会影响SVM分类模型的使用效果？

- 模型的学习过程中是否存在类别不均衡问题？
- 样本是否进行了规范化预处理？
- 分类模型的学习是否进行了超参数的优选？

编程作业:

1. 以鸢尾花数据集为例，分别实现基于线性SVM、RBF-SVM的分类模型。
 - (1)取前两类，实现两类别分类
 - (2)多类别分类