

## 第二部分 非线性分类

### Kernel-LDA

*Kernel Fisher's Discriminant Analysis (KFDA)*

--监督式非线性特征提取(降维)

张朝晖

2018-2019学年 2018年10月

## 1. 分类模块

### 产生式分类模型

### A. 贝叶斯分类模型

### 判别式分类模型 线性分类模型

#### B. Fisher判别分类

#### C. 感知器分类模型

#### D. 大间隔分类模型 (线性SVM)

### 非线性分类模型

#### E. 核SVM (非线性SVM)

#### F. 核Fisher判别分类

#### G. 神经网络 (bp, autoencoder, som)

### 其它分类模型

#### H. KNN分类模型

#### I. 决策树分类模型

#### J. Logistic回归

#### K. Softmax回归

## 2. 聚类模块

### L. K-均值聚类

### M. 高斯混合聚类

### N. DBSCAN聚类

### O. 层次聚类

## 3. 回归模块

### P. KNN回归

### Q. 回归树

### R. 最小二乘线性回归

### S. 岭回归

### T. LASSO回归

## 4. 集成学习

### U. Bagging

### V. 随机森林

### W. Boosting

### (AdaBoost, GBDT, XGBoost)

### (lightGBM, CatBoost)

## 5. 特征工程

### X. 主成分分析 (PCA)

### Y. kernel-PCA, ISOMAP, LLE

### Z. SOM

## 6. 评价模块

混淆矩阵 (及其相关指标)、ROC曲线、交叉验证

**核Fisher判别**是基于**核技巧**，将原始空间的  
**Fisher线性判别**向**非线性问题**的推广

⇒ **非线性Fisher判别**

## 1. 回顾Fisher线性判别

**基本思想** 将 $d$ 维原始空间样本投影到某方向直线上(1维空间); 在该方向投影线上, 能最大限度区分各类数据点, 最易分类.

$\begin{cases} \text{类间样本尽可能远离} \\ \text{类内样本尽可能聚集} \end{cases}$

**线性分类器设计** ⇒ **寻找最佳投影直线方向**

## *Fisher*准则函数

原始 $d$ 维空间样本直接投影到1维空间

{ 类间样本尽量分开  $\Rightarrow$  投影后类间离散度  $\uparrow$   
类内样本尽量聚集  $\Rightarrow$  投影后总类内离散度  $\downarrow$

$\Rightarrow$

*Fisher*准则

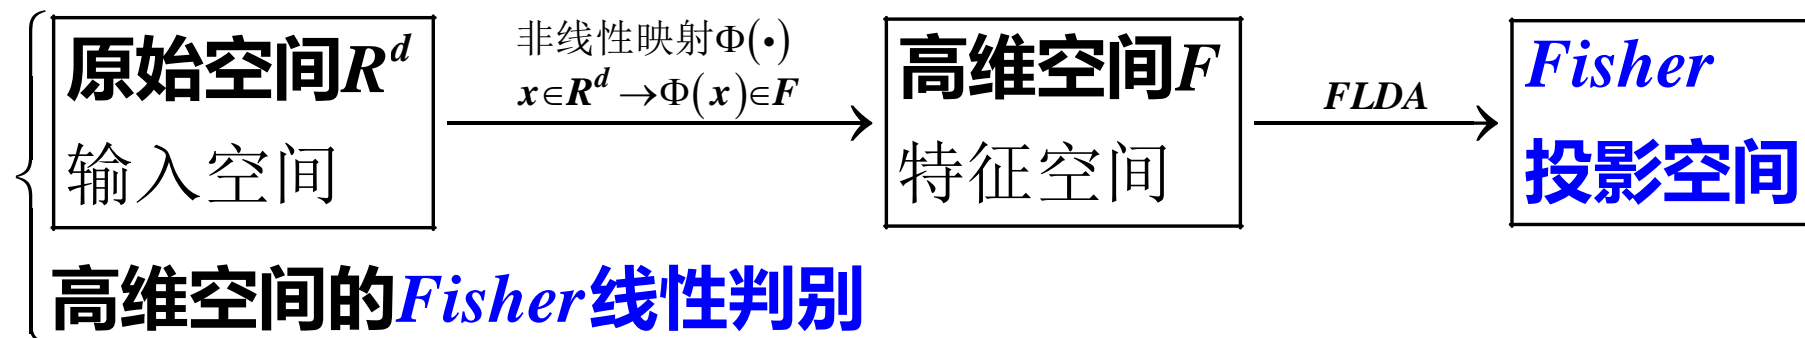
$$\max_w J_F(w) = \frac{w^T S_B w}{w^T S_w w}$$

*Fisher*准则函数  $J_F(w)$

$$w^* = \arg \max_w J_F(w)$$

若 $S_w$ 可逆，则**最优投影方向**  $w^* = S_w^{-1} (m_1 - m_2)$

## 2.非线性*Fisher*判别--核*Fisher*判别(KFDA)



(1) 将训练样本非线性变换

$$x \in R^d \rightarrow \Phi(x) \in F$$

(2) 在变换空间 $F$ 中的*Fisher*线性判别

*Fisher*线性判别准则  $J(w) = \frac{w^T S_B^\Phi w}{w^T S_W^\Phi w}$

其中  $\begin{cases} w -- \text{F空间的权值向量, } w \in F \\ S_B^\Phi -- \text{训练样本集在F空间的类间散度矩阵} \\ S_W^\Phi -- \text{训练样本集在F空间总类内散度矩阵} \end{cases}$

$$\text{若} \left\{ \begin{array}{l} \text{第}i\text{类训练样本数量}l_i \quad \sum_i l_i = l \\ \text{第}i\text{类训练样本在}\mathbf{F}\text{空间的均值}\mathbf{m}_i^\Phi \\ \mathbf{m}_i^\Phi = \frac{1}{l_i} \sum_{j=1}^{l_i} \Phi(\mathbf{x}_j^i) \quad i = 1, 2 \\ \text{各类先验概率相等: } \mathbf{P}(\omega_1) = \mathbf{P}(\omega_2) = 0.5 \end{array} \right.$$

$$\text{则} \left\{ \begin{array}{l} \mathbf{S}_B^\Phi = (\mathbf{m}_1^\Phi - \mathbf{m}_2^\Phi)(\mathbf{m}_1^\Phi - \mathbf{m}_2^\Phi)^T \\ \mathbf{S}_W^\Phi = \sum_{i=1}^2 \sum_{j=1}^{l_i} (\Phi(\mathbf{x}_j^i) - \mathbf{m}_i^\Phi)(\Phi(\mathbf{x}_j^i) - \mathbf{m}_i^\Phi)^T \end{array} \right.$$

(3)转化为**核函数**的求解形式

**再生核理论认为，鉴别向量 $w \in F$ 处于F空间所有训练样本所张成的子空间中，即：**

$$w = \sum_{j=1}^l \alpha_j \Phi(x_j)$$

**原始空间任意观测 $x$ 在Fisher判别方向的投影为：**

$$\begin{aligned} w^T \Phi(x) &= (w, \Phi(x)) = \left( \sum_{j=1}^l \alpha_j \Phi(x_j), \Phi(x) \right) \\ &= \sum_{j=1}^l \alpha_j (\Phi(x_j), \Phi(x)) = \sum_{j=1}^l \alpha_j k(x_j, x) \end{aligned}$$

$$\begin{aligned}
\mathbf{w}^T \mathbf{m}_i^\Phi &= \mathbf{w}^T \frac{1}{l_i} \sum_{k=1}^{l_i} \Phi(\mathbf{x}_k^i) = \left( \sum_{j=1}^l \alpha_j \Phi(\mathbf{x}_j) \right)^T \frac{1}{l_i} \sum_{k=1}^{l_i} \Phi(\mathbf{x}_k^i) \\
&= \frac{1}{l_i} \sum_{j=1}^l \sum_{k=1}^{l_i} \alpha_j \left( \Phi(\mathbf{x}_j), \Phi(\mathbf{x}_k^i) \right) = \frac{1}{l_i} \sum_{j=1}^l \sum_{k=1}^{l_i} \alpha_j \mathbf{k}(\mathbf{x}_j, \mathbf{x}_k^i) \\
&= \sum_{j=1}^l \alpha_j \left[ \frac{1}{l_i} \sum_{k=1}^{l_i} \mathbf{k}(\mathbf{x}_j, \mathbf{x}_k^i) \right] = \sum_{j=1}^l \alpha_j (M_i)_j = \boldsymbol{\alpha}^T \mathbf{M}_i \quad i = 1, 2
\end{aligned}$$

其中

$$\begin{cases}
\text{核函数 } \mathbf{k}(\mathbf{x}_j, \mathbf{x}_k^i) = \left( \Phi(\mathbf{x}_j), \Phi(\mathbf{x}_k^i) \right) \\
(M_i)_j = \frac{1}{l_i} \sum_{k=1}^{l_i} \mathbf{k}(\mathbf{x}_j, \mathbf{x}_k^i) \\
\mathbf{M}_i = \left[ (M_i)_1 \quad \cdots \quad (M_i)_l \right]^T \quad l = l_1 + l_2 \\
\boldsymbol{\alpha} = [\alpha_1 \quad \cdots \quad \alpha_l]^T
\end{cases}$$



**规定**  $M = (M_1 - M_2)(M_1 - M_2)^T$

由前页知:  $w^T \mathbf{m}_i^\Phi = \alpha^T M_i \quad i = 1, 2$

## 投影空间类间离散度

$$\begin{aligned} w^T S_B^\Phi w &= \mathbf{w}^T \left( \mathbf{m}_1^\Phi - \mathbf{m}_2^\Phi \right) \left( \mathbf{m}_1^\Phi - \mathbf{m}_2^\Phi \right)^T w \\ &= \alpha^T (M_1 - M_2) (M_1 - M_2)^T \alpha = \alpha^T M \alpha \end{aligned}$$

## 投影空间类内离散度

$$\begin{aligned} w^T S_W^\Phi w &= \sum_{i=1}^2 \sum_{j=1}^{l_i} \mathbf{w}^T \left( \Phi(x_j^i) - \mathbf{m}_i^\Phi \right) \left( \Phi(x_j^i) - \mathbf{m}_i^\Phi \right)^T \mathbf{w} \\ &= \sum_{i=1}^2 \sum_{j=1}^{l_i} \left( \mathbf{w}^T \Phi(x_j^i) - \mathbf{w}^T \mathbf{m}_i^\Phi \right) \left( \mathbf{w}^T \Phi(x_j^i) - \mathbf{w}^T \mathbf{m}_i^\Phi \right)^T \\ &= \alpha^T N \alpha \end{aligned}$$

$$\mathbf{w}^T \mathbf{S}_B^\Phi \mathbf{w} = \boldsymbol{\alpha}^T \mathbf{M} \boldsymbol{\alpha}$$

$$\mathbf{w}^T \mathbf{S}_W^\Phi \mathbf{w} = \boldsymbol{\alpha}^T \mathbf{N} \boldsymbol{\alpha}$$

$$\left\{ \begin{array}{l} \mathbf{N} = \sum_{i=1,2} \mathbf{K}_i \left( \mathbf{I} - \mathbf{1}_{l_i} \right) \mathbf{K}_i^T \quad \text{\textcolor{blue}{}l行 \times l列} \\ \mathbf{K}_i \text{ -- \textcolor{blue}{}l行 \times l_i列 矩阵} \\ (\mathbf{K}_i)_{nm} = k(\mathbf{x}_n, \mathbf{x}_m^i) \text{ -- } \mathbf{K}_i \text{ 矩阵的第 } \mathbf{n} \text{ 行第 } \mathbf{m} \text{ 列元素} \\ \mathbf{I} \text{ -- 单位矩阵,} \quad l_i \text{ 行} \times l_i \text{ 列} \\ \mathbf{1}_{l_i} \text{ -- 所有元素均为 } \frac{1}{l_i} \text{ 的矩阵} \end{array} \right.$$

变换空间**Fisher**线性判别的目标函数

$$J(\alpha) = \frac{\alpha^T M \alpha}{\alpha^T N \alpha}$$

最大化 $J(\alpha)$ ，得最优解方向为  $\alpha^* \propto N^{-1}(\mathbf{M}_1 - \mathbf{M}_2)$

原始空间任意观测 $\mathbf{x}$ 在**Fisher**判别方向的投影为：

$$\begin{aligned} y &= (\mathbf{w}^*)^T \Phi(\mathbf{x}) = (\mathbf{w}^*, \Phi(\mathbf{x})) = \left( \sum_{j=1}^l \alpha_j^* \Phi(\mathbf{x}_j) \right)^T \Phi(\mathbf{x}) \\ &= \sum_{j=1}^l \alpha_j^* (\Phi(\mathbf{x}_j), \Phi(\mathbf{x})) = \sum_{j=1}^l \alpha_j^* k(\mathbf{x}_j, \mathbf{x}) \end{aligned}$$

#### (4)决策

**STEP1.** 估计各类训练样本点在**Fisher**判别方向投影中心

$$f_i = \mathbf{w}^{*T} \mathbf{m}_i^\Phi = \frac{1}{l_i} \sum_{j=1}^l \alpha_j^* \sum_{k=1}^{l_i} k(\mathbf{x}_j, \mathbf{x}_k^i) = \boldsymbol{\alpha}^{*T} \mathbf{M}_i \quad i = 1, 2$$

**STEP2.** 确定原始空间任意观测 $\mathbf{x}$ 在**Fisher**判别方向投影

$$y = \mathbf{w}^{*T} \Phi(\mathbf{x}) = \sum_{j=1}^l \alpha_j^* k(\mathbf{x}_j, \mathbf{x})$$

**STEP3.** 决策

$$\begin{cases} \text{若 } |y - f_1| < |y - f_2|, \text{ 则决策 } \mathbf{x} \in \omega_1 \text{ 类} \\ \text{若 } |y - f_1| > |y - f_2|, \text{ 则决策 } \mathbf{x} \in \omega_2 \text{ 类} \end{cases}$$

### 3.基本核Fisher判别方法的改进

由最大化  $\frac{\alpha^T M \alpha}{\alpha^T N \alpha}$ , 得最优解方向为

$$\alpha \propto N^{-1} (M_1 - M_2)$$

若 $N$ 非正定, 则上述求解为病态

**改进：**

引入新矩阵  $N_\mu = N + \mu I$ , 使矩阵 $N_\mu$ 正定

其中 $\mu$ 为正常数

# 思考

核LDA的基本思想、实现步骤？